

Relatório Técnico de Engenharia de IA: Ouvidoria Inteligente

Triagem Semântica, Detecção de Duplicatas e Chunking de Manifestações Cidadãs

Equipa: Mateus Ieno Ramalho | Heitor De Oliveira Mamede | João Gabriel Barreto de Araújo Falcão

Auxílio: Antigravity (Gemini 3.8 Flash)

Disciplina: Tendências em Ciência da Computação | **Instituição:** UNIPÊ - Cruzeiro do Sul | **Setembro de 2026**

1. Sumário Executivo e Contexto do Problema

A Ouvidoria Geral do Município recebe cerca de 4.000 manifestações mensais abrangendo infraestrutura urbana, saúde pública, iluminação e trânsito. O sistema legado apoiava-se em filtros estáticos por palavras-chave exatas, exibindo três falhas críticas:

- Incapacidade de Detecção de Duplicatas Semânticas:** Textos com vocabulário diferente sobre o mesmo problema geravam tickets duplicados e dispersão de equipas.
- Fragmentação Temática:** Ausência de agregação conceptual de queixas correlacionadas sob as mesmas prioridades de gestão pública.
- Perda de Contexto em Relatos Extensos (> 500 caracteres):** Indexar a queixa como bloco único diluía detalhes e gerava falsos negativos na busca.

Implementou-se um pipeline moderno com *Sentence Embeddings* densos, segmentação recursiva contextual (*chunking*) e interface interativa em Streamlit.

2. Decisões Técnicas de Engenharia e Arquitetura

- Pipeline Geral:** Receção da manifestação → Decisor de comprimento (≤ 500 caracteres: indexação direta; > 500 : chunking com sobreposição) → Codificação vetorial densa → Módulos de identificação de duplicatas, recuperação Top-K e projecção 2D.
- Modelo de Embeddings:** paraphrase-multilingual-MiniLM-L12-v2 (12 camadas, dimensão $d = 384$). Viabiliza inferência rápida em CPU (~470 MB de RAM, tempo < 15 ms/frase) e compreensão precisa da linguagem coloquial e abreviações em português brasileiro.
- Métrica de Similaridade:** Cosseno no espaço euclidiano normalizado: $\text{sim}(u, v) = (u \cdot v) / (\|u\|_2 \cdot \|v\|_2)$.
- Estratégia de Chunking:** RecursiveCharacterTextSplitter com separadores hierárquicos ["\n\n", "\n", " ", " "].
- Interface e Caching:** Aplicação modular Streamlit otimizada com `@st.cache_resource` e `@st.cache_data` para latência nula na navegação.

3. Síntese e Discussão das Entregas

3.1. Entrega 1 — Análise Comparativa de Representações

Confrontaram-se representações lexicais tradicionais (BoW, TF-IDF) e vetores densos (MiniLM):

Par de Frases / Contexto	Hipótese Avaliada	BoW	TF-IDF	MiniLM
"buraco enorme na Av. Brasil" × "asfalto todo esburacado da avenida principal"	Sinónimos em infraestrutura sem termos idênticos	0.0000	0.0000	0.2870
"posto de saúde sem médico" × "falta atendimento no PSF"	Equivalência semântica com sigla e perífrase em saúde	0.0000	0.0000	0.2859

Par de Frases / Contexto	Hipótese Avaliada	BoW	TF-IDF	MiniLM
"posto de saúde sem médico" × "lâmpada queimada na praça"	Cruzamento negativo entre domínios distintos	0.0000	0.0000	0.0061
M001 ("Rua das Flores, buracos") × M071 ("Rua das Flores, crateras")	Paráfrase real de alta severidade na base municipal	0.3043	0.1239	0.7975
M002 ("Posto sem médico") × M062 ("Fila no posto, só um médico")	Duas queixas de sobrecarga hospitalar no município	0.2433	0.2322	0.4470

Modelos lexicais falham devido à hipótese de ortogonalidade de vocabulário. O modelo MiniLM mapeia o sentido no hiperespaço latente, distinguindo paráfrases reais de temas disjuntos.

3.2. Entrega 2 — Detecção Automatizada de Duplicatas

Análise da matriz 100 × 100 (4.950 pares únicos) para calibração estatística do limiar (θ):

Percentil / Métrica	Score	Interpretação Operacional
Percentil 50 (Mediana)	0.2621	Distância semântica típica entre queixas não correlacionadas.
Percentil 75 / 90	0.3951 / 0.5211	Vocabulário comum da gestão pública / mesmo macrodomínio.
Percentil 95 / 98	0.5924 / 0.6849	Subtemas específicos / proximidade contextual elevada.
Percentil 99.4 ($\theta = 0.82$)	0.8200	Limiar Ótimo de Agrupamento: seleciona o topo de 0,6% mais redundante.
Percentil 99.5	0.8537	Paráfrases quase literais ou duplicatas sintéticas.

Com $\theta = 0.82$, foram identificados 35 pares redundantes (ex: M001 × M091 com score 0.9585; M029 × M089 com 0.9484).

Alerta de Engenharia: Reclamações com teor sintático idêntico em ruas diferentes não devem ser fundidas sem conferência geográfica via NER. Queixas extensas exigem chunking para evitar falsos negativos gerados pela diluição vetorial.

3.3. Entrega 3 — Estratégia de Chunking para Textos Longos

Experimentos nos textos mais longos da base (> 600 caracteres: M051 e M056):

Caso de Teste	Configuração	Chunks	Sim. Média	Coesão	Observação Analítica
M051 (600 car. - Asfalto)	A (chunk 200 / ovlp 20)	4	0.5338	Moderada	Corte de sujeito na fronteira.
M051 (600 car. - Asfalto)	B (chunk 200 / ovlp 100)	5	0.7259	Excelente	+36,0% ganho; transição fluida.
M056 (756 car. - R. Flores)	A (chunk 200 / ovlp 20)	5	0.5199	Moderada	Quebra temporal no relato.
M056 (756 car. - R. Flores)	B (chunk 200 / ovlp 100)	7	0.7192	Excelente	+38,3% ganho; contexto íntegro.

O overlap de 100 caracteres preserva o elo anafórico entre blocos consecutivos. A projeção PCA 2D confirmou agrupamento coeso dos fragmentos originados do mesmo texto.

3.4. Entrega 4 — Buscador Semântico e Aplicação Streamlit

A aplicação app_ouvidoria.py foi estruturada em 4 abas funcionais:

1. **Busca Semântica:** Consulta livre com semáforo de relevância: Verde (> 0.70), Amarelo (0.50 a 0.70) e Vermelho (< 0.50).
2. **Base e Matriz:** Listagem interativa do dataset e cálculo da matriz de calor de similaridade.
3. **Espaço 2D (PCA/t-SNE):** Projeção dimensional mostrando separação nítida das categorias oficiais.
4. **Laboratório de Chunking:** Ajuste dinâmico de tamanho e sobreposição com métricas de coesão em tempo real.

4. Dificuldades Enfrentadas e Soluções Adotadas

Desafio	Causa Raiz	Solução de Engenharia
Linguagem Coloquial e Ruído	Erros ortográficos e gírias regionais	MiniLM multilíngue pré-treinado em dados reais.
Calibração do Limiar	Falta de limiar empírico provocando ruído	Calibração estatística no percentil 99.4 ($\theta = 0.82$).
Desempenho no Navegador	Cálculo e renderização de matrizes grandes	Cache em memória com <code>@st.cache_data</code> .
Diluição de Textos Longos	Perda de detalhes em queixas de múltiplos tópicos	Chunking recursivo com sobreposição de 100 caracteres.

5. Recomendações e Próximos Passos

- **Pipeline Híbrido com NER:** Condicionar agrupamento semântico à correspondência de entidades de logradouro e bairro.
- **Geração com RAG:** Elaboração automatizada de minutas de despacho e resposta ao munícipe.
- **Canal Multimodal:** Adição de transcrição Whisper para áudio e OCR para imagens de queixas.
- **Monitoramento de Deriva (Drift):** Acompanhar desvios temáticos para identificar surtos sazonais na saúde ou infraestrutura.

6. Conclusão

O pipeline comprovou elevada robustez e viabilidade computacional para o setor público, operando com baixa latência (< 15 ms/frase em CPU), calibração estatística sólida ($\theta = 0.82$) e preservação contextual em queixas extensas (+38% de coesão), estando tecnicamente pronto para ambiente operacional.

7. Referências Bibliográficas

- Reimers, N., & Gurevych, I. (2019). *Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks*. EMNLP.
- Devlin, J., et al. (2018). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. arXiv.
- LangChain Documentation. (2024). *RecursiveCharacterTextSplitter Concepts and Guides*.
- Sentence-Transformers Documentation. (2024). *Pretrained Models for Semantic Search*.
- Streamlit Inc. (2024). *Streamlit Caching and State Architecture*.