

RELATÓRIO TÉCNICO DE ENGENHARIA DE IA: OUVIDORIA INTELIGENTE

Triagem Semântica, Detecção de Duplicatas e Chunking de Manifestações Cidadãs

Equipa: Mateus Ieno Ramalho | Heitor De Oliveira Mamede | João Gabriel Barreto de Araújo Falcão

Disciplina: Tendências em Ciência da Computação | Instituição: UNIPÊ – Cruzeiro do Sul | Setembro de 2026

1. Sumário Executivo e Contexto do Problema

A Ouvidoria Geral do Município recebe cerca de 4.000 manifestações mensais abrangendo infraestrutura urbana, saúde pública, iluminação e trânsito. O sistema legado baseava-se em filtros estáticos por palavras-chave exatas, apresentando falhas críticas:

- Incapacidade de Detecção de Duplicatas Semânticas:** Reclamações que descreviam a mesma falha com termos distintos geravam ordens de serviço redundantes e dispersão de recursos.
- Fragmentação Temática:** Ausência de agregação estratégica de manifestações correlatas sob as mesmas prioridades de gestão.
- Perda de Contexto em Relatos Extensos (> 500 caracteres):** A indexação monolítica diluía detalhes circunstanciais essenciais em queixas longas.

O presente projeto concebeu e implementou um pipeline moderno fundamentado em *Sentence Embeddings* densos, segmentação recursiva contextual (chunking) e interface analítica em Streamlit.

2. Decisões Técnicas de Engenharia e Arquitetura

- Pipeline:** Receção da manifestação → Decisor de tamanho (≤ 500 caracteres: indexação direta; > 500 : chunking com sobreposição) → Codificação vetorial densa → Módulos de identificação de duplicatas, recuperação Top-K e projeção 2D.
- Modelo de Embeddings:** paraphrase-multilingual-MiniLM-L12-v2 (12 camadas, dimensão $d = 384$). Viabiliza operação em CPU (~470 MB de RAM, tempo de inferência < 15 ms/frase) e compreensão precisa do vernáculo coloquial brasileiro.
- Métrica de Similaridade:** Cosseno no espaço euclidiano normalizado: $\text{sim}(u, v) = (u \cdot v) / (||u||_2 ||v||_2)$.
- Estratégia de Chunking:** RecursiveCharacterTextSplitter (LangChain) com separadores hierárquicos `['\n\n', '\n', ' ', '']`.
- Interface e Caching:** Aplicação interativa em Streamlit otimizada com `@st.cache_resource` e

@st.cache_data.

3. Síntese e Discussão das Entregas

3.1. Entrega 1 — Análise Comparativa de Representações

Confrontaram-se representações lexicais tradicionais (BoW, TF-IDF) e vetores densos (MiniLM):

Par Analisado	Hipótese / Cenário	BoW	TF-IDF	MiniLM
<i>buraco enorme na Av. Brasil × asfalto todo esburacado da avenida principal</i>	Sinónimos em infraestrutura sem termos idênticos	0.0000	0.0000	0.2870
<i>posto de saúde sem médico × falta atendimento no PSF</i>	Equivalência semântica com sigla e perífrase em saúde	0.0000	0.0000	0.2859
<i>posto de saúde sem médico × lâmpada queimada na praça</i>	Cruzamento negativo entre domínios distintos	0.0000	0.0000	0.0061
M001 (Rua das Flores, buracos) × M071 (Rua das Flores, crateras)	Paráfrase real de alta severidade na base municipal	0.3043	0.1239	0.7975
M002 (Posto sem médico) × M062 (Fila no posto, só um médico)	Duas queixas de sobrecarga hospitalar no município	0.2433	0.2322	0.4470

Os modelos BoW e TF-IDF falham por assumirem ortogonalidade estrita entre palavras distintas. Os embeddings contínuos superam essa restrição projetando conceitos próximos em regiões vizinhas do hiperespaço.

3.2. Entrega 2 — Detecção Automatizada de Duplicatas

Avaliou-se a matriz completa 100×100 (4.950 pares únicos não triviais) para calibrar o limiar de agrupamento (θ):

Métrica / Percentil	Score de Cosseno	Interpretação Operacional
Percentil 50 (Mediana)	0.2621	Distância semântica típica entre queixas não relacionadas
Percentil 75 / 90	0.3951 / 0.5211	Vocabulário comum da gestão pública / mesmo macrodomínio
Percentil 95 / 98	0.5924 / 0.6849	Subtemas específicos / proximidade contextual elevada
Percentil 99.4 ($\theta = 0.82$)	0.8200	Limiar Ótimo de Agrupamento: seleciona o topo de 0,6% mais redundante
Percentil 99.5	0.8537	Paráfrases quase literais ou duplicatas sintéticas

Com o limiar $\theta = 0.82$, foram identificados 35 pares redundantes (e.g., M001 $\times$ M091 com score 0.9585; M029 $\times$ M089 com 0.9484).

Alerta de Engenharia — Falsos Positivos por Localização: Demandas com sintaxe e teor idênticos em bairros distintos não podem ser unificadas sem conferência geográfica (necessidade de NER). Do mesmo modo, relatos extensos podem gerar falsos negativos se analisados apenas pela média global do vetor, reforçando a importância do chunking.

3.3. Entrega 3 — Estratégia de Chunking para Textos Longos

Comparação experimental em manifestações com mais de 600 caracteres (M051 e M056):

- **Configuração A:** chunk_size = 200, chunk_overlap = 20
- **Configuração B:** chunk_size = 200, chunk_overlap = 100

Manifestação	Configuração	Chunks	Similaridade Média	Coesão	Preservação Contextual
M051 (600 car. - Asfalto)	Config A (200 / 20)	4	0.5338	Moderada	Corte abrupto do sujeito oracional na fronteira
M051 (600 car. - Asfalto)	Config B (200 / 100)	5	0.7259 (+36,0%)	Excelente	Transição suave e vínculo mantido entre causa e queixa
M056 (756 car. - Asfalto)	Config A (200 / 20)	5	0.5199	Moderada	Perda de vínculo

Manifestação	Configuração	Chunks	Similaridade Média	Coesão	Preservação Contextual
Rua das Flores)	20)				temporal no relato do acidente
M056 (756 car. - Rua das Flores)	Config B (200 / 100)	7	0.7192 (+38,3%)	Excelente	Entidades, logradouro e queixas preservados em bloco

A sobreposição de 100 caracteres funciona como elo de coesão, eliminando anáforas órfãs. A análise por PCA 2D confirmou trajetórias contínuas e agrupamento compacto dos fragmentos de um mesmo texto.

3.4. Entrega 4 — Buscador Semântico e Aplicação Streamlit

A aplicação modular app_ouvidoria.py organiza as operações em quatro interfaces:

- 1. **Busca Semântica com Semáforo UX:** Consultas em linguagem natural com retorno imediato categorizado em Verde (> 0.70), Amarelo (0.50 a 0.70) e Vermelho (< 0.50).
- 2. **Base e Matriz de Calor:** Consulta aos registros e inspeção visual da similaridade intra-base.
- 3. **Espaço Reduzido 2D (PCA e t-SNE):** Projeção das 384 dimensões em 2D com separabilidade clara entre áreas da administração.
- 4. **Laboratório de Chunking:** Simulação interativa com ajuste de parâmetros e medição de coesão em tempo real.

4. Dificuldades Enfrentadas e Soluções Adotadas

Desafio	Causa Raiz	Solução de Engenharia
Linguagem Informal e Ruído	Gírias, regionalismos e pontuação irregular	MiniLM multilíngue robusto, dispensando limpezas destrutivas
Calibração de Limiar	Valores arbitrários causavam subnotificação ou falsos alarmes	Calibração estatística empírica em $\theta = 0.82$ (percentil 99.4)
Renderização $N \times N$	Sobrecarga de renderização do heatmap no navegador	Otimização gráfica contínua associada a cache de memória
Diluição em Textos Longos	Multiplicidade de queixas atenuando o	Chunking recursivo (200/100) com

Desafio	Causa Raiz	Solução de Engenharia
	vetor global	ganho de +38% de coesão

5. Recomendações e Próximos Passos

- **Triagem Híbrida (Semântica + NER):** Combinar o score semântico com reconhecimento de entidades nomeadas para condicionar a fusão à identidade de localidade e endereço.
- **Geração Aumentada por Recuperação (RAG):** Produzir minutas automáticas de resposta ao munícipe e termos de encaminhamento para as equipes operacionais.
- **Integração Multimodal:** Incorporar transcrição de mensagens de voz (Whisper) e leitura de comprovativos via OCR.
- **Monitoramento de Deriva Semântica (Drift):** Acompanhar alterações nas distribuições latentes para sinalizar surtos ou emergências sazonais atípicas.

6. Conclusão

O pipeline comprovou a viabilidade técnica e econômica da triagem por representações densas no setor público. O sistema conjuga resposta ágil (< 15 ms por frase em CPU), fundamentação estatística ($\theta = 0.82$) e coesão textual em relatos extensos (+38%), configurando uma ferramenta pronta para ambiente de produção.

7. Referências Bibliográficas

- Reimers, N., & Gurevych, I. (2019). *Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks*. EMNLP.
- Devlin, J., et al. (2018). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. arXiv.
- LangChain Documentation. (2024). *RecursiveCharacterTextSplitter Concepts and Guides*.
- Sentence-Transformers Documentation. (2024). *Pretrained Models for Semantic Search*.
- Streamlit Inc. (2024). *Streamlit Caching and State Architecture*.